

Journal of Comprehensive Science
p-ISSN: 2962-4738 e-ISSN: 2962-4584
Vol. 4. No. 3 March 2025

Implementasi Teknologi OCR dan Model LLM untuk Otomatisasi Pengisian Formulir Berdasarkan Dokumen Sertifikat untuk Universitas Esa Unggul Bekasi

Calvin Samuel Angelino Simanjorang^{1*}, Nixon Erzed²

Universitas Esa Unggul, Bekasi, Indonesia

Email: calvinsamuel08@gmail.com^{1*}, nixon@esaunggul.ac.id²

Author koresponden: calvinsamuel08@gmail.com^{1*}

Abstrak

Administrasi dokumen di institusi pendidikan, seperti Universitas Esa Unggul, kerap menghadapi tantangan dalam pengisian formulir yang dilakukan secara manual, sehingga memakan waktu dan rentan terhadap kesalahan manusia. Penelitian ini mengembangkan sistem otomatisasi pengisian formulir berbasis teknologi Optical Character Recognition (OCR) dan Large Language Model (LLM). Teknologi OCR digunakan untuk mengekstraksi teks dari dokumen sertifikat secara otomatis, sementara LLM digunakan untuk memahami konteks dan mengidentifikasi informasi spesifik, seperti nama, judul kegiatan, dan tanggal pelaksanaan. Metode penelitian menggunakan pendekatan waterfall, dengan analisis Fishbone Diagram untuk mengidentifikasi akar masalah dan desain sistem menggunakan General OCR Theory (GOT) untuk ekstraksi teks serta model Llama 3 untuk interpretasi data. Sistem diuji dengan berbagai format sertifikat untuk mengevaluasi tingkat akurasi dan efisiensi dibandingkan metode manual. Hasilnya menunjukkan bahwa sistem mampu mencapai akurasi lebih dari 90%, mengurangi kesalahan input, dan mempercepat proses pengisian formulir. Kesimpulannya bahwa sistem yang dikembangkan telah berhasil meningkatkan efisiensi, akurasi, dan keandalan proses administrasi di Universitas Esa Unggul. Sistem ini diharapkan dapat diimplementasikan untuk mendukung administrasi kampus yang lebih efisien dan akurat, serta menjadi dasar pengembangan teknologi otomatisasi dokumen di masa depan.

Kata kunci: *optical character recognition; large language model; otomatisasi dokumen; efisiensi administrasi; universitas esa unggul*

Abstract

Document administration at educational institutions, such as Esa Unggul University, often faces challenges in filling out forms manually, making them time-consuming and prone to human error. This research develops a form filling automation system based on Optical Character Recognition (OCR) and Large Language Model (LLM) technology. OCR technology is used to extract text from certificate documents automatically, while LLMs are used to understand context and identify specific information, such as names, activity titles, and execution dates. The research method used a waterfall approach, with Fishbone Diagram analysis to identify the root of the problem and system design using General OCR Theory (GOT) for text extraction as well as the Llama 3 model for data interpretation. The system is tested with a variety of certificate formats to evaluate the level of accuracy and efficiency compared to manual methods. The results showed that the system was able to achieve an accuracy of more than 90%, reduce input errors, and speed up the form filling process. He concluded that the developed system has succeeded in improving the efficiency, accuracy, and reliability of the administrative process at Esa Unggul University. This system is expected to be implemented to support more efficient and accurate campus administration, as well as be the basis for the development of document automation technology in the future.



PENDAHULUAN

Di era digital, pengelolaan dokumen digital menjadi suatu keharusan di berbagai sektor, terutama di bidang pendidikan yang terus berkembang pesat (Zuchroh, 2024). Universitas Esa Unggul, sebagai institusi pendidikan tinggi yang berkomitmen dalam memberikan kualitas terbaik, memerlukan sistem yang efisien untuk mengelola dan memproses dokumen-dokumen penting yang berkaitan dengan administrasi mahasiswa. Salah satu aspek penting dalam administrasi universitas adalah sertifikat yang digunakan sebagai bukti keikutsertaan mahasiswa dalam kegiatan tertentu, seperti seminar, pelatihan, dan kegiatan lainnya yang menjadi persyaratan untuk kelulusan.

Pada saat ini, proses verifikasi dan pengisian informasi dari sertifikat-sertifikat ini ke dalam sistem kampus masih dilakukan secara manual oleh petugas administrasi. Setiap data penting, seperti nama peserta, jenis kegiatan, tanggal pelaksanaan, dan aspek lainnya, harus diinput satu per satu, yang tentu membutuhkan waktu dan tenaga yang cukup besar. Proses manual ini tidak efisien dan juga rentan terhadap kesalahan manusia (*human error*) seperti salah ketik atau kesalahan dalam menginput data (Nirawati & Seibinna, 2024). Dalam konteks sertifikat untuk syarat kelulusan, akurasi data menjadi sangat penting karena kesalahan dalam pencatatan dapat berdampak serius pada status kelulusan mahasiswa.

Untuk mengatasi masalah ini, teknologi *Optical Character Recognition* (OCR) dan *Large Language Model* (LLM) dapat dimanfaatkan. OCR memungkinkan sistem untuk mengekstraksi teks secara otomatis dari gambar sertifikat, sehingga informasi yang terdapat di dalam sertifikat dapat diproses dengan cepat (Bashori et al., 2023; Pratomo et al., 2022). Namun, hasil ekstraksi OCR umumnya masih memerlukan pemrosesan lanjutan karena informasi yang diekstraksi seringkali belum terstruktur dengan baik. Di sinilah *Large Language Model* (LLM), seperti Llama 3.3 70B (*Large Language Model Meta AI*), dapat berperan penting. LLM memiliki kemampuan memahami konteks teks dan secara otomatis mengidentifikasi informasi spesifik yang diperlukan, seperti nama, jenis kegiatan, dan tanggal (Prakoso, 2024; Sulianta, 2024). Dengan teknologi ini, sistem dapat mengotomatisasi pengisian data ke dalam formulir kelulusan dan juga mengklasifikasikan informasi dari sertifikat secara akurat dan cepat. Kombinasi OCR dan LLM memberikan solusi otomatisasi pengisian formulir yang tidak hanya efisien tetapi juga akurat, sehingga risiko *Human Error* dapat diminimalkan.

Penelitian terdahulu yang relevan antara lain penelitian oleh Banu et al., (2023) menemukan bahwa meskipun OCR efektif dalam mengekstraksi teks dari dokumen seperti sertifikat, proses ini sering kali memerlukan verifikasi manual untuk meningkatkan akurasi dan memastikan bahwa data yang diekstraksi telah terstruktur dengan benar. Penelitian lain oleh Mu'alifah & Haviana, (2025) yang menunjukkan bahwa LLM dapat meningkatkan efisiensi dalam memahami konteks teks dan mengekstraksi informasi yang relevan, namun tantangan tetap ada dalam mengintegrasikan teknologi ini dengan sistem yang ada.

Novelty penelitian ini terletak pada penggabungan OCR dan LLM dalam satu sistem terintegrasi untuk otomatisasi pengisian formulir kelulusan di Universitas Esa Unggul. Meskipun penelitian terdahulu telah meneliti OCR dan LLM secara terpisah, penelitian ini mengusulkan

pendekatan yang menggabungkan kedua teknologi untuk meningkatkan akurasi, efisiensi, dan mengurangi kesalahan manusia dalam pengolahan sertifikat. Dengan sistem ini, proses pengisian formulir menjadi lebih cepat dan akurat, sekaligus mengurangi beban kerja petugas administrasi.

Penelitian ini bertujuan untuk mengembangkan sistem otomatisasi pengisian formulir berdasarkan data sertifikat dengan memanfaatkan teknologi OCR dan LLM. Secara spesifik, penelitian ini berupaya membuat sistem yang dapat memvalidasi informasi dalam sertifikat guna mencegah pengisian data yang tidak sesuai oleh mahasiswa, mengekstrak teks secara otomatis dari dokumen sertifikat dengan tingkat akurasi tinggi, serta mengolah hasil ekstraksi tersebut untuk menghasilkan informasi spesifik seperti nama, judul acara, dan tanggal sertifikat secara otomatis, sekaligus mengevaluasi akurasi dan efisiensi sistem dibandingkan dengan metode manual. Manfaat dari penelitian ini meliputi peningkatan efisiensi waktu, peningkatan akurasi data, dan kemudahan dalam proses verifikasi syarat kelulusan oleh pihak administrasi kampus, sehingga dapat menyederhanakan proses pengisian formulir dan mengurangi kesalahan input data. Lingkup penelitian ini dibatasi pada pengembangan sistem di Universitas Esa Unggul, khususnya di Kampus Bekasi, dengan fokus pada otomatisasi pengisian formulir akademik berbasis data sertifikat dalam Bahasa Indonesia, yang mencakup pengolahan informasi seperti nama mahasiswa, judul kegiatan, penyelenggara, dan tanggal kegiatan melalui penggunaan teknologi OCR untuk mengubah teks dari gambar sertifikat menjadi teks digital, serta pemanfaatan model LLM untuk menafsirkan hasil OCR dan mengekstrak informasi secara spesifik.


METODE PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif eksperimental dengan tujuan untuk mengembangkan dan menguji sistem otomatisasi pengisian formulir menggunakan teknologi Optical Character Recognition (OCR) dan Large Language Model (LLM). Pendekatan eksperimental ini digunakan untuk mengukur dan membandingkan efisiensi serta akurasi pengisian data dengan sistem otomatis dibandingkan dengan metode manual yang ada. Penelitian ini berfokus pada analisis dan pengembangan teknologi untuk mengurangi kesalahan input, mempercepat proses administrasi, serta meningkatkan akurasi dalam pengisian formulir kelulusan.


Desain penelitian ini merupakan desain penelitian pengembangan (developmental research) yang bertujuan untuk merancang, mengembangkan, dan menguji sistem otomatisasi berbasis OCR dan LLM. Penelitian ini dilakukan dalam beberapa tahap, dimulai dengan analisis masalah melalui Fishbone Diagram untuk mengidentifikasi akar masalah dalam proses manual pengisian formulir, diikuti oleh perancangan dan pengembangan sistem, dan akhirnya dilakukan pengujian untuk mengevaluasi efisiensi dan akurasi sistem yang dikembangkan. Hasil pengujian akan digunakan untuk membandingkan sistem otomatis dengan metode manual dalam hal waktu dan akurasi pengisian data formulir.

Model Konseptual

Model konseptual yang dikembangkan dalam penelitian ini bertujuan untuk menggambarkan proses penelitian ini.




Gambar 1. Konsep sebelum sistem dibuat



Gambar 2. Konsep setelah sistem dibuat

Kerangka Penelitian

Penelitian ini bertujuan mengembangkan sistem otomatisasi pengisian formulir dengan memanfaatkan teknologi Optical Character Recognition (OCR) dan Large Language Model (LLM). Sistem ini dirancang untuk mengurangi kesalahan input, mempercepat proses administrasi, dan memastikan akurasi data yang tinggi dalam pengisian formulir kelulusan (Andriyani et al., 2024; Bardvall & Hassle, 2024; Timilehin, 2024). Untuk mencapai tujuan tersebut, penelitian ini menggunakan pendekatan Fishbone Diagram sebagai alat analisis utama dalam mengidentifikasi dan memahami akar masalah pada proses manual yang saat ini digunakan.



Gambar 3. Diagram Fishbone

Tahapan yang dilakukan dalam analisis Fishbone adalah sebagai berikut:

1. **Identifikasi Masalah Utama:** Masalah utama adalah ketidakefisienan dalam pengisian formulir kelulusan dari sertifikat, yang sering menyebabkan kesalahan input dan memakan waktu lama.
2. **Kategorisasi Penyebab Masalah:** Setiap penyebab masalah dikategorikan dalam empat faktor utama:
 - a. **Manusia (People)**
 - 1) **Validator**
 - a) Tidak mengikuti prosedur standar → Menyebabkan kesalahan data pada formulir.
 - b) Kelalaian dalam verifikasi → Menyebabkan kesalahan input dan ketidakefisienan. Beban kerja yang tinggi
 - 2) **Mahasiswa**
 - a) Kesalahan ketik saat mengisi data → Menghasilkan data yang tidak sesuai format.
 - b) Tidak memahami instruksi → Menyebabkan kesalahan input.
 - b. **Metode (Methods)**
 - 1) Verifikasi manual yang tidak efisien → Menyebabkan proses pengisian yang lambat dan rawan kesalahan.
 - 2) Proses manual yang berlebihan → Memperpanjang waktu pengerjaan dan meningkatkan kemungkinan kesalahan.
 - c. **Mesin (Machines)**
 - 1) Tidak bisa melakukan verifikasi otomatis → Mengakibatkan ketergantungan pada manusia yang berisiko meningkatkan kesalahan.
 - 2) Tidak optimal pada format yang beragam → Menyebabkan akurasi rendah.
 - d. **Material (Materials)**

- 1) Variasi format sertifikat → Menyulitkan sistem dalam mengenali format yang tidak standar.
 - 2) Jenis font dan ukuran teks yang beragam → Menyebabkan kesalahan dalam pembacaan teks.
 - 3) Warna atau latar belakang tidak seragam → OCR mengalami kesulitan dalam mengenali teks dengan akurat.
3. Analisis Akar Masalah: Setelah penyebab-penyebab utama dikategorikan, dilakukan analisis mendalam untuk setiap kategori guna mengidentifikasi akar permasalahan. Hasil analisis ini kemudian digunakan untuk menentukan solusi yang tepat dalam merancang sistem otomatisasi yang meminimalkan masalah-masalah ini.

Tahapan Pengembangan Sistem

Setelah akar masalah diidentifikasi melalui Fishbone Diagram, tahap selanjutnya adalah pengembangan sistem otomatisasi berbasis OCR dan LLM. Tahapan ini meliputi beberapa langkah berikut:

1. Desain Alur Sistem:
 - a. Menyusun diagram alur kerja untuk sistem, termasuk diagram alir (flowchart) dan diagram use case untuk menggambarkan proses otomatisasi dari input sertifikat hingga pengisian data ke formulir kelulusan.
 - b. Setiap langkah dalam alur kerja didokumentasikan secara rinci agar setiap fungsi sistem dapat dipahami dengan baik.
2. Pengembangan dan Integrasi OCR:
 - a. Menggunakan Tesseract OCR untuk mengekstrak teks dari dokumen sertifikat. Tahap ini mencakup pengaturan parameter Tesseract untuk mencapai akurasi tinggi, khususnya dalam membaca informasi yang bervariasi seperti nama, tanggal, dan jenis kegiatan.
 - b. Hasil ekstraksi dari OCR kemudian dianalisis untuk memastikan format data yang sesuai sebelum diproses lebih lanjut oleh LLM.
3. Pemanfaatan LLM untuk Analisis Teks:
 - a. Menggunakan model LLM, seperti Llama 3, untuk menafsirkan teks hasil OCR dan mengidentifikasi informasi spesifik yang dibutuhkan (nama, acara, tanggal).
 - b. LLM disesuaikan untuk mengenali pola teks dalam dokumen sertifikat, sehingga mampu mengklasifikasikan informasi secara otomatis dan menempatkannya pada field yang tepat dalam formulir.
4. Pemodelan dan Desain Database:

Sistem ini menggunakan database untuk menyimpan hasil ekstraksi teks dari OCR dan output dari LLM. Perancangan database dilakukan dengan mempertimbangkan kebutuhan untuk mengelola informasi sertifikat secara terstruktur, termasuk informasi seperti nama mahasiswa, jenis acara, dan tanggal pelaksanaan.
5. Pengujian Sistem:
 - a. Melakukan pengujian black box untuk memastikan bahwa sistem berfungsi sesuai dengan spesifikasi yang telah dirancang, khususnya dalam akurasi ekstraksi OCR dan klasifikasi LLM.

- b. Membandingkan hasil pengisian data otomatis dengan metode manual untuk mengevaluasi efisiensi dan akurasi sistem. Pengujian ini dilakukan pada beberapa sampel sertifikat yang berbeda untuk memastikan sistem bekerja secara konsisten.

Pengumpulan Data

Data yang digunakan dalam penelitian ini berasal dari:

1. Dokumen Sertifikat Mahasiswa: Beragam format dan konten dokumen sertifikat digunakan untuk menguji sistem OCR dan LLM.
2. Data Waktu dan Akurasi Pengisian Formulir: Data diperoleh melalui uji coba pengisian sertifikat baik secara manual maupun dengan sistem otomatis. Data ini kemudian dianalisis untuk melihat perbedaan efisiensi antara kedua metode.

HASIL DAN PEMBAHASAN

Implementasi Model GOT dan Llama 3.3

1. Implementasi Optical Character Recognition (OCR) dengan Model GOT

Dalam sistem ini, Model GOT digunakan dengan konfigurasi Plain Multi-Crop OCR dan Format Multi-Crop OCR. Langkah implementasinya:

- a. Pra-pemrosesan Gambar:
 - 1) Pemotongan Multi-Crop: Dokumen sertifikat dipecah menjadi beberapa bagian (crop) berdasarkan area teks yang relevan. Teknik ini memastikan pengenalan teks optimal meskipun format dokumen bervariasi.
 - 2) Resolusi Dinamis: Model mendukung dokumen resolusi tinggi (>2K) dengan fitur adaptasi resolusi untuk mempertahankan detail teks.
- b. Ekstraksi dan Pengkodean Teks:
 - 1) Plain Multi-Crop OCR: Ekstraksi teks dilakukan pada level potongan gambar (line atau paragraph level), memastikan semua bagian teks terbaca dengan jelas.
 - 2) Format Multi-Crop OCR: Format dokumen seperti tabel, tanggal, dan elemen struktural lainnya dipertahankan dalam hasil keluaran. Model menghasilkan representasi terstruktur, mendukung markdown dan format dokumen lainnya.

2. Pemanfaatan Llama 3.3 (70B Versatile)

Llama 3.3 dengan kapasitas 70B parameter dipilih karena kemampuan versatile-nya yang mendukung pemrosesan konteks multi-bahasa hingga 128K token. Tahapan implementasinya:

- a. Klasifikasi Informasi dan Mapping ke Formulir:
 - 1) Model menerima keluaran dari GOT OCR dan memetakan informasi penting seperti nama peserta, judul acara, dan tanggal pelaksanaan ke field formulir yang relevan.
 - 2) Dengan kemampuan reasoning dan multilinguality, Llama 3.3 mampu menangani data dalam Bahasa Indonesia dan format campuran lainnya dengan akurasi tinggi.
- b. Penyempurnaan Hasil dengan Pemrosesan Kontekstual:
 - 1) Llama 3.3 dilatih dengan dataset spesifik berbasis sertifikat untuk meningkatkan kemampuan identifikasi pola lokal seperti gelar akademik atau format tanggal tertentu.

Pelatihan Model

1. Pelatihan Model OCR

Proses pelatihan model *General OCR Theory* (GOT) ini dilakukan melalui tiga tahap utama:

Tahap 1: Pre-training Encoder

Pada tahap ini, encoder dilatih untuk memahami berbagai jenis data teks yang berasal dari gambar, baik dalam bentuk potongan teks (*slices*) maupun dokumen penuh (*full-page*) (Singh & Karayev, 2021).

a. Arsitektur Encoder

- 1) Encoder berbasis ViTDet dengan 80 juta parameter, dirancang untuk menghasilkan representasi token gambar yang terkompresi dengan dimensi 256×1024 .
- 2) Input gambar diubah menjadi ukuran 1024×1024 piksel untuk memastikan kompatibilitas dengan berbagai format dokumen.

b. Dataset yang Digunakan

- 1) Scene Text OCR:
 - a) Dataset: Laion-2B dengan total 3 juta pasangan data teks-gambar.
 - b) Labeling: Proses labeling menggunakan PaddleOCR, di mana bounding box teks diidentifikasi, lalu teks disusun ulang dalam urutan top-to-bottom dan left-to-right.
- 2) Document OCR:
 - a) Dataset: Common Crawl (PDF-style files) dengan total 2 juta pasangan data teks.
 - b) Format: Dataset ini terdiri dari 1,2 juta data dokumen penuh dan 0,8 juta data slice (line-level dan paragraph-level).
 - c) Teknik: Data PDF diproses menggunakan library Fitz untuk memisahkan teks dan bounding box, memungkinkan ekstraksi teks yang lebih akurat.

Tahap 2: Joint-training Encoder-Decoder

Setelah pre-training selesai, encoder yang telah dilatih digabungkan dengan decoder berbasis Qwen-0.5B, menghasilkan model GOT dengan total 580 juta parameter. Proses ini bertujuan untuk memperluas kemampuan model dalam memahami berbagai format data OCR yang lebih kompleks (Wei et al., 2024).

c. Dataset yang Digunakan

- 1) Tabel
 - a) Data tabel dirender dalam format LATEX, menghasilkan 0,3 juta pasangan data.
- 2) Formula Matematika
 - a) Ekstraksi 1 juta formula dari file LATEX di Arxiv, dirender menggunakan Mathpix-markdown-it untuk menghasilkan gambar.
- 3) Molekul
 - a) Dataset: ChEMBL_25.
 - b) Total: 1 juta pasangan data formula molekul, dirender dalam format gambar menggunakan tools rdkit.Chem dan Mathpix.
- 4) Geometri
 - a) Bentuk geometris sederhana dirender menggunakan TikZ, menghasilkan dataset sintetik untuk pengenalan bentuk geometris.
- 5) Musik Lembaran
 - a) Dataset: GrandStaff, dengan total 500 ribu lembar musik yang dirender menggunakan Verovio Python Package.
- 6) Proses Joint-training

- a) Joint-training dilakukan untuk memadukan kemampuan encoder dalam memahami teks visual dengan kemampuan decoder dalam menghasilkan keluaran berbasis teks.
- b) Dataset sintetis dari berbagai tugas digunakan untuk memperluas cakupan kemampuan model, termasuk dokumen multi-halaman dan data kompleks seperti tabel dan musik lembaran.

Tahap 3: Post-training dan Fine-tuning

Tahap ini bertujuan untuk menyempurnakan performa model GOT dengan menambahkan data tambahan serta teknik pelatihan canggih (Jiang et al., 2024).

1) Data Sintetis Tambahan

- a) Dataset multi-halaman untuk dokumen PDF, dirancang untuk melatih model dalam menangani dokumen yang panjang.
- b) Dataset beresolusi tinggi, memungkinkan model memproses teks dalam resolusi ultra-tinggi untuk skenario OCR khusus.

2) Teknik Dynamic Resolution

- a) Digunakan untuk meningkatkan fleksibilitas model dalam memproses teks dari berbagai resolusi gambar.
- b) Teknologi ini memungkinkan model untuk menangani dokumen dengan resolusi yang sangat tinggi tanpa mengorbankan akurasi.

d. Evaluasi Model

1) Pengujian Model

GOT diuji pada berbagai skenario OCR, termasuk pengenalan teks potongan (*slices*), dokumen penuh (*full-page*), dan dokumen dengan elemen kompleks seperti tabel, geometri, dan musik.

2) Metrik Evaluasi

- a. Model dievaluasi menggunakan metrik standar seperti Precision, Recall, dan F1 Score.
- b. Hasil pengujian menunjukkan peningkatan akurasi yang signifikan dibandingkan OCR tradisional, terutama pada dokumen dengan elemen kompleks.

2. Pelatihan Model LLM

Model Llama 3.3, bagian dari keluarga model bahasa Llama 3, dirancang untuk menangani tugas-tugas yang memerlukan pemrosesan bahasa alami, penalaran, dan pemetaan teks secara efisien. Model ini menggunakan arsitektur Transformer yang mendukung konteks panjang hingga 128 ribu token. Pelatihan model dilakukan melalui dua tahap utama:

Tahap 1: Pre-training Foundation Model

Tahap ini merupakan langkah awal untuk melatih model Llama 3.3 dengan skala besar, mencakup beberapa proses sebagai berikut:

a. Arsitektur Model

- 1) Model ini terdiri dari 405 miliar parameter dan didukung oleh metode Grouped Query Attention (GQA) yang mempercepat inferensi sekaligus mengurangi memori yang dibutuhkan.
- 2) Dengan panjang konteks hingga 128 ribu token, model ini mampu menangani dokumen dengan struktur yang kompleks dan data berurutan dalam jumlah besar.

b. Dataset yang Digunakan

- 1) Dataset yang digunakan terdiri dari 15 triliun token teks multibahasa, termasuk data untuk reasoning, kode, dan general knowledge.
- 2) Proporsi dataset adalah sebagai berikut:
 - a. 50% general knowledge, meliputi teks umum seperti artikel ilmiah dan berita.
 - b. 25% reasoning dan matematika, untuk mendukung kemampuan logika dan analisis.
 - c. 17% kode, diambil dari corpus kode untuk mendukung pemahaman sintaks dan semantik pemrograman.
 - d. 8% multilingual, yang meliputi teks dalam berbagai bahasa untuk mendukung kemampuan multibahasa.
3. Filtering Dataset

Untuk memastikan kualitas data, dataset melalui proses filtering yang mencakup:

 - a. De-duplication di tingkat URL, dokumen, dan baris untuk menghindari pengulangan data.
 - b. Penghapusan data yang mengandung PII (Personally Identifiable Information) dan konten dewasa.
 - c. Penyaringan kualitas menggunakan classifier berbasis fasttext dan Roberta, memastikan bahwa hanya data berkualitas tinggi yang digunakan.
4. Proses Tokenisasi

Data teks diubah menjadi token diskrit menggunakan tokenizer berbasis tiktoken, yang mengoptimalkan representasi data untuk proses pelatihan pada skala besar.

Tahap 2: Post-training dengan Fine-tuning

Setelah pre-training selesai, model Llama 3.3 dilatih ulang untuk meningkatkan keselarasan dengan instruksi dan kebutuhan pengguna melalui metode *Supervised Fine-Tuning (SFT)* dan *Direct Preference Optimization (DPO)*.

 - a. Supervised Fine-Tuning (SFT)

Pada tahap ini, model dilatih menggunakan dataset yang dirancang khusus untuk memperkuat kemampuan instruksionalnya, seperti memahami pertanyaan kompleks, menyusun jawaban, dan mengikuti instruksi pengguna.
 - b. Direct Preference Optimization (DPO)

DPO digunakan untuk menyelaraskan hasil keluaran model dengan preferensi manusia, sehingga hasil akhir lebih relevan dan sesuai dengan ekspektasi pengguna.
 - c. Integrasi Alat dan Penyesuaian Konteks Panjang
 - 1) Model dilengkapi dengan alat seperti Mathpix untuk pengenalan tabel dan formula, yang mendukung pengolahan data berbasis format kompleks seperti LATEX dan Markdown.
 - 2) Konteks panjang model ditingkatkan hingga 128 ribu token, memungkinkannya menangani dokumen yang sangat panjang, seperti laporan teknis atau buku.

Tahap 3: Evaluasi Model

Model Llama 3.3 diuji pada berbagai benchmark untuk mengukur performanya:

 - a. Benchmark yang Digunakan
 - 1) MMLU (Massive Multitask Language Understanding): Menguji kemampuan reasoning dan pemahaman multibahasa.
 - 2) GSM8K: Benchmark untuk soal matematika dan penalaran logis.
 - b. Hasil Evaluasi

Model Llama 3.3 menunjukkan performa yang setara dengan GPT-4 dalam berbagai tugas benchmark, termasuk reasoning dan pemrosesan teks panjang.

Studi Kasus

Untuk mengevaluasi kinerja sistem, dilakukan studi kasus pada 10 sertifikat dengan 2 metode *Plain Multi-Crop OCR* dan *Format Multi-Crop OCR*.

Hasil Evaluasi

Untuk Menghitung akurasi OCR, dilakukan perhitungan menggunakan *Word-Level Accuracy* dan *Character-Level Accuracy* untuk setiap sertifikat.

1. Sertifikat 1

Tabel 1. Sertifikat 1 Word-Level Accuracy dan Character-Level Accuracy

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		7.69%	86.79%
Character-Level Accuracy (CLA)		6.84%	78.42%

2. Sertifikat 2

Tabel 2. Sertifikat 2 Word-Level Accuracy dan Character-Level Accuracy

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		14,01%	76.63%
Character-Level Accuracy (CLA)		17,43%	78,58%

3. Sertifikat 3

Tabel 3. Sertifikat 3 Word-Level Accuracy dan Character-Level Accuracy

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		91,66%	95%
Character-Level Accuracy (CLA)		94,31%	94,60%

4. Sertifikat 4

Tabel 4. Sertifikat 4 Word-Level Accuracy dan Character-Level Accuracy

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		97,72%	100%
Character-Level Accuracy (CLA)		100%	100%

5. Sertifikat 5

Tabel 5. Sertifikat 5 *Word-Level Accuracy* dan *Character-Level Accuracy*

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		71,11%	66,66%
Character-Level Accuracy (CLA)		73,33%	65,66%

6. Sertifikat 6

Tabel 6. Sertifikat 6 *Word-Level Accuracy* dan *Character-Level Accuracy*

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		96%	58%
Character-Level Accuracy (CLA)		98,47%	54,87%

7. Sertifikat 7

Tabel 7. Sertifikat 7 *Word-Level Accuracy* dan *Character-Level Accuracy*

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		0%	94,11%
Character-Level Accuracy (CLA)		0%	93,37%

8. Sertifikat 8

Tabel 8. Sertifikat 8 *Word-Level Accuracy* dan *Character-Level Accuracy*

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		0%	100%
Character-Level Accuracy (CLA)		0%	100%

9. Sertifikat 9

Tabel 9. Sertifikat 9 *Word-Level Accuracy* dan *Character-Level Accuracy*


Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		63,63%	72,72%

Character-Level Accuracy (CLA)	63,74%	65,64%
--------------------------------	--------	--------

10. Sertifikat 10

Tabel 10. Sertifikat 10 Word-Level Accuracy dan Character-Level Accuracy

Hasil		Plain Multi-Crop OCR	Format Multi-Crop OCR
Word-Level Accuracy (WLA)		100%	86,95%
Character-Level Accuracy (CLA)		100%	85,22%



Gambar 4. Grafik Hasil Evaluasi Semua Sertifikat

Analisis Perbandingan Waktu

Untuk mengevaluasi kinerja sistem, dilakukan studi kasus pada beberapa sertifikat dengan membandingkan pengisian manual dengan sistem otomatis

1. Sertifikat 1

Tabel 11. Sertifikat 1 Perbandingan Pengisian Manual dengan Sistem Otomatis

Manual	Sistem Otomatis
23 detik	6 detik

2. Sertifikat 2

Tabel 12. Sertifikat 2. Perbandingan Pengisian Manual dengan Sistem Otomatis

Manual	Sistem Otomatis
53 detik	5 detik

3. Sertifikat 3

Tabel 13. Sertifikat 3. Perbandingan Pengisian Manual dengan Sistem Otomatis

Manual	Sistem Otomatis
60 detik	7 detik

4. Sertifikat 4

Tabel 14. Sertifikat 4 Perbandingan Pengisian Manual dengan Sistem Otomatis

Manual	Sistem Otomatis
60 detik	7 detik

5. Sertifikat 5

Tabel 15. Sertifikat 5 Perbandingan Pengisian Manual dengan Sistem Otomatis

Manual	Sistem Otomatis
55 detik	6 detik

Analisis Format File pada Sistem OCR

Dalam sistem otomatisasi pengisian data sertifikat berbasis OCR, proses unggahan file menjadi langkah awal yang penting (Darmawan et al., 2021). Sistem mendukung dua jenis file, yaitu PDF dan gambar (seperti PNG atau JPG). Namun, hasil eksperimen menunjukkan bahwa mengunggah gambar memiliki beberapa keunggulan signifikan dibandingkan konversi dari PDF ke gambar menggunakan `convert_from_path` dari library `pdf2image`.

1. Efisiensi Proses

a. Mengurangi Langkah Konversi:

- 1) Saat mengunggah PDF, sistem harus mengonversi setiap halaman menjadi gambar menggunakan `convert_from_path`. Proses ini membutuhkan waktu tambahan dan memperpanjang jalur pemrosesan.
- 2) Dengan mengunggah gambar langsung, sistem dapat langsung memproses file tanpa perlu langkah konversi tambahan, sehingga waktu pemrosesan menjadi lebih cepat.

b. Peningkatan Kinerja:

Konversi dari PDF ke gambar membutuhkan sumber daya komputasi yang lebih besar, terutama untuk dokumen dengan resolusi tinggi atau banyak halaman. Mengunggah gambar langsung mengurangi beban sistem, terutama dalam skenario dengan banyak pengguna.

2. Kontrol Resolusi

- a. Ketika PDF dikonversi ke gambar, resolusi gambar ditentukan oleh pengaturan DPI pada fungsi `convert_from_path`. Resolusi yang tidak optimal dapat menghasilkan gambar buram (jika DPI terlalu rendah) atau terlalu besar (jika DPI terlalu tinggi), yang keduanya memengaruhi akurasi OCR.
- b. Dengan mengunggah gambar, pengguna dapat memastikan resolusi gambar sudah sesuai sejak awal, sehingga hasil OCR lebih akurat tanpa perlu eksperimen tambahan.

3. Kesederhanaan untuk Pengguna

Mengunggah gambar lebih mudah dipahami dan dilakukan oleh pengguna dibandingkan harus mengunggah PDF yang memerlukan proses konversi tambahan di sisi sistem.

Dari hasil eksperimen, ditemukan bahwa pengaturan DPI (300, 600, 1200) memberikan hasil yang tidak selalu konsisten. Beberapa sertifikat menghasilkan hasil OCR yang bagus, sementara lainnya justru menghasilkan hasil yang jelek, bahkan berupa angka atau karakter acak. Hal ini menunjukkan bahwa pengaturan DPI bukan satu-satunya faktor penentu akurasi OCR,

tetapi juga dipengaruhi oleh karakteristik dokumen dan kemampuan model OCR (Kleinhans, 2023).

1. Faktor-Faktor yang Mempengaruhi Variasi Hasil

a. Kualitas Sumber Dokumen

- 1) Dokumen Berkualitas Tinggi: DPI 300 sering cukup untuk dokumen dengan teks tajam dan tanpa noise visual yang signifikan. DPI 600 atau 1200 dapat menangkap detail kecil pada dokumen berkualitas tinggi, tetapi noise juga ikut terdeteksi.
- 2) Dokumen Berkualitas Rendah: DPI tinggi dapat memperbesar noise atau artefak pada dokumen (seperti bayangan, garis halus, atau latar belakang), yang menyebabkan hasil OCR menjadi tidak akurat.

b. Kompleksitas Desain Sertifikat

- 1) Desain Sederhana: Sertifikat dengan teks rapi, font standar, dan latar belakang polos biasanya memberikan hasil OCR yang baik pada DPI 300 atau 600.
- 2) Desain Kompleks: Sertifikat dengan elemen grafis, tabel, atau watermark lebih sulit diproses. Pada DPI tinggi (600 atau 1200), noise dari elemen dekoratif dapat menghasilkan angka atau simbol acak.

c. Ukuran Teks

- 1) Teks kecil memerlukan DPI lebih tinggi (600–1200) agar dapat terbaca jelas oleh model OCR.
- 2) Namun, jika DPI terlalu tinggi, elemen dekoratif atau noise kecil dapat diinterpretasikan sebagai teks.

d. Kemampuan Model OCR

- 1) Model OCR, seperti GOT-OCR, memiliki rentang optimal resolusi yang didukung. DPI terlalu rendah (<300) atau terlalu tinggi (>600) dapat menyebabkan model kehilangan akurasi.
- 2) Model juga cenderung salah mengenali pola tertentu sebagai karakter jika resolusi terlalu detail.

Tabel 16. Spesifikasi Kemampuan Model OCR

DPI	Hasil OCR	Analisis Masalah
300	Teks terbaca jelas untuk desain sederhana	Resolusi cukup untuk teks rapi, tetapi gagal untuk dokumen dengan teks kecil atau dekorasi.
600	Teks kecil terbaca, tetapi noise terlihat	Noise dari elemen dekoratif atau garis tabel ikut terdeteksi sebagai teks atau angka acak.
1200	Teks kecil terbaca, tapi banyak hasil salah	Detail noise menjadi dominan, model salah mengenali pola sebagai angka atau simbol acak.

KESIMPULAN

Berdasarkan hasil dan pembahasan, serta implementasi dan evaluasi sistem otomatisasi pengisian formulir berbasis data sertifikat yang menggunakan teknologi OCR dan LLM, penelitian ini menyimpulkan bahwa sistem yang dikembangkan telah berhasil meningkatkan efisiensi, akurasi, dan keandalan proses administrasi di Universitas Esa Unggul. Sistem ini mampu mengurangi waktu pemrosesan satu dokumen sertifikat hingga 70% dibandingkan dengan metode manual, sehingga sangat efisien untuk skala besar. Selain itu, model OCR yang diterapkan berhasil mengekstraksi teks dengan akurasi tinggi, dan integrasinya dengan LLM meningkatkan akurasi dalam klasifikasi serta pengisian data, terutama dalam penentuan nama, tanggal, dan judul acara, dengan kesalahan yang minimal. Penggunaan sistem otomatis juga terbukti mampu mereduksi risiko kesalahan input data yang umum terjadi pada proses manual, seperti kesalahan pengetikan dan inkonsistensi format data. Dengan demikian, sistem ini tidak hanya meningkatkan produktivitas dan keandalan data, tetapi juga memberikan kontribusi signifikan terhadap peningkatan kualitas administrasi akademik, menyediakan solusi teknologi yang modern dan mendukung pengalaman pengguna yang lebih baik bagi mahasiswa dan staf administrasi.

DAFTAR PUSTAKA

- Andriyani, W., Purnomo, R., Hendrawan, S. A., Irvani, A. I., Sujarwo, A., Asri, Y. N., Jones, A. H. S., Feta, N. R., Wulandari, I. Y., & Hatma, S. (2024). *Data Sebagai Fondasi Kecerdasan Buatan*. Tohar Media.
- Banu, K., Andreas, D., Anggoro, W., & Setiawan, A. (2023). OCR: Masa Depan Pengenalan Karakter Optik dan Dampaknya pada Kehidupan Modern. *Jurnal Teknologi Informasi*, 9(2), 147–156.
- Bardvall, M., & Hassle, I. (2024). *Automating Invoice Recognition: A Comparative Study of Large Language Models and OCR/ML Technologies*.
- Bashori, A. H., Rosita, Y. D., & Akbar, R. M. (2023). Penerapan Metode OCR Dan Colour Feature Extraction Untuk Identifikasi Pelat Nomor Kendaraan. *Seminar Nasional Fakultas Teknik*, 2(1), 43–48.
- Darmawan, R., Nasuha, A., Zaman, L., & Armanto, H. (2021). Sistem Manajemen Kartu Nama dengan OCR dan Ekstraksi Informasi Otomatis. *INSYST: Journal of Intelligent System and Computation*, 3(2), 61–72.
- Jiang, J., Yang, J., Zhang, Y., Wang, Z., You, H., & Chen, J. (2024). A post-training framework for improving the performance of deep learning models via model transformation. *ACM Transactions on Software Engineering and Methodology*, 33(3), 1–41.
- Kleinhans, R. (2023). *Towards a framework for intelligent document image enhancement in pursuit of improved OCR performance*. Stellenbosch: Stellenbosch University.
- Mu'alifah, E., & Haviana, S. F. C. (2025). Perancangan Sistem Peringkasan Artikel Ilmiah Menggunakan Grobid Dan Karge Language Models (LLM) Berbasis SciBERT. *Jurnal Rekayasa Sistem Informasi Dan Teknologi*, 2(3), 1094–1102.
- Nirawati, L., & Seibinna, T. M. (2024). Optimalisasi Proses Stock Opname Alat Tulis Kantor (ATK) Melalui Digitalisasi Quick Response Code (Qr Code) Pada PT Surabaya Industrial Estate Rungkut (SIER). *Socius: Jurnal Penelitian Ilmu-Ilmu Sosial*, 1(11).
- Prakoso, B. S. (2024). *Perancangan Chatbot sebagai Sales Agent Berbasis Large Language Model dengan Teknik Retrieval Augmented Generation di Layanan XL Home PT XL*

Axiata Tbk.

- Pratomo, D. N., Putri, D. U. K., & Azhari, A. (2022). Implementasi Optical Character Recognition berbasis Deep Learning untuk Ekstraksi Data Sertifikat Tanah. *Jurnal Informatika: Jurnal Pengembangan IT*, 7(3), 131–134.
- Singh, S. S., & Karayev, S. (2021). Full page handwriting recognition via image to sequence extraction. *Document Analysis and Recognition–ICDAR 2021: 16th International Conference, Lausanne, Switzerland, September 5–10, 2021, Proceedings, Part III* 16, 55–69.
- Sulianta, F. (2024). *Chat GPT-Memberdayakan Large Language Model untuk Berbagai Kebutuhan*. Feri Sulianta.
- Timilehin, O. (2024). *Enhancing Industrial Efficiency: The Evolution and Applications of Robust Optical Character Recognition Systems*.
- Wei, H., Liu, C., Chen, J., Wang, J., Kong, L., Xu, Y., Ge, Z., Zhao, L., Sun, J., & Peng, Y. (2024). *General ocr theory: Towards ocr-2.0 via a unified end-to-end model*.
- Zuchroh, I. (2024). Transformasi Keuangan Syariah di Era Digital. *Innovative: Journal Of Social Science Research*, 4(1), 3716–3724.